第 1 课：认识 DeepSeek API 与首次调用

从账号、鉴权到第一个可观测请求

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 理解 API、模型、Token、SDK 的关系
- 安全配置 API Key，并分别用 HTTP 与 OpenAI SDK 调用
- 选择 `deepseek-flash` / `deepseek-v4-pro`
- 查询模型、余额并读懂最小响应

全课程能力阶梯

鉴权与对话 → 流式与推理 → 结构化与工具

→ 视觉/文件/搜索 → 多协议兼容 → 生产 Agent

本节路线

1. 基本概念
2. 鉴权与环境
3. 首次调用
4. 成本与练习

一次调用的组成

请求

端点 + Bearer Key + 模型 + 输入消息 + 生成参数

响应

候选结果 + 停止原因 + Token 用量 + 请求标识

DeepSeek API 是无状态服务：客户端负责保存需要延续的对话。

当前模型选择

模型	主要定位	图像输入
`deepseek-flash`	速度、成本、视觉	支持
`deepseek-v4-pro`	高质量复杂任务	不支持

两者支持 1M 上下文、思考模式、JSON、工具、Responses 与 Anthropic 格式。能力和价格会更新，应以官方模型页为准。

地址与兼容层

OpenAI 格式 `https://api.deepseek.com`

Anthropic 格式 `https://api.deepseek.com/anthropic`

Beta 功能 `https://api.deepseek.com/beta`

“兼容”表示可复用 SDK 与请求形态，不代表所有上游字段都生效。第 10、11 课逐项核对差异。

本节路线

1. 基本概念
2. 鉴权与环境
3. 首次调用
4. 成本与练习

Key 只放环境变量

```
# PowerShell: 仅当前终端会话
$env:DEEPSEEK_API_KEY="sk-..."
$env:DEEPSEEK_MODEL="deepseek-flash"
```

禁止

不要提交 Key、打印 Key、放进前端、日志或示例截图；泄漏后立即吊销并轮换。

HTTP 鉴权

```
Authorization: Bearer <API_KEY>
```

JSON 请求还需 `Content-Type: application/json`。常见失败：

- 401：Key 缺失、拼写错误、已失效
- 402：余额不足
- 400/422：JSON 或字段不合法

本节路线

1. 基本概念
2. 鉴权与环境
3. 首次调用
4. 成本与练习

OpenAI SDK 最小调用

```
client = OpenAI(
    api_key=os.environ["DEEPSEEK_API_KEY"],
    base_url="https://api.deepseek.com",
)
response = client.chat.completions.create(
    model="deepseek-flash",
    messages=[{"role": "user", "content": "你好"}],
    max_tokens=64,
)
print(response.choices[0].message.content)
```

最小响应阅读法

`id` 请求/结果标识，排障时记录

`choices[0].message` 助手消息

`finish_reason` stop、length、tool_calls 等

`usage` 输入、输出、总 Token 与缓存明细

`system_fingerprint` 后端配置指纹

先检查停止原因，再消费内容，最后记录 usage。

模型与余额端点

- `GET /models`：运行时发现模型及能力元数据
- `GET /user/balance`：读取余额可用状态与币种明细
- 余额是账号级；模型列表适合健康检查，不应每请求查询

本节路线

1. 基本概念
2. 鉴权与环境
3. 首次调用
4. 成本与练习

Token 与计费直觉

总费用通常由未命中输入、缓存命中输入、输出分别计价；Search/Fetch 按成功请求次数计费。

实际 Token 以响应 `usage` 为准；中文字符、英文单词与 Token 并非固定一一对应。

本课例程

1. `01_first_call.py`：SDK 最小调用与 usage
2. `02_raw_http.py`：理解裸 HTTP 请求
3. `03_account_info.py`：模型列表与余额

练习：比较两个模型的延迟、输出与 Token；不要把单次结果当成基准测试。

检查清单

- Key 未进入源码或版本库
- 显式设置超时与 `max_tokens`
- 记录 id、model、finish_reason、usage
- 不硬编码价格；上线前复核官方页面

官方资料

https://api-docs.deepseek.com/zh-cn/
https://api-docs.deepseek.com/zh-cn/quick_start/pricing
https://api-docs.deepseek.com/zh-cn/quick_start/token_usage
https://api-docs.deepseek.com/zh-cn/api/list-models
https://api-docs.deepseek.com/zh-cn/api/get-user-balance