第 2 课：Chat Completions 基础

消息、参数、响应与多轮状态

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 掌握 `POST /chat/completions` 的消息协议
- 理解采样、长度、停止序列与停止原因
- 构造多轮对话，并控制上下文增长
- 区分支持、忽略与已废弃参数

本节路线

1. 消息协议
2. 生成参数
3. 响应处理
4. 多轮对话

四种消息角色

system	设定长期行为、边界与输出原则
user	用户输入；文本或多模态内容块
assistant	历史模型输出；可含工具调用/推理内容
tool	客户端工具结果，用 `tool_call_id` 配对

顺序就是上下文；API 不会替你记住上一轮。

最小请求体

```
{
  "model": "deepseek-flash",
  "messages": [
    {"role": "system", "content": "回答简洁、准确。"},
    {"role": "user", "content": "解释幂等性。"}
  ],
  "max_tokens": 256,
  "thinking": {"type": "disabled"}
}
```

必填字段只有 `model` 和非空 `messages`。

提示分层

1. system：身份、规则、失败方式、输出语言
2. user：任务、上下文、数据、验收标准
3. 用分隔符隔离“指令”和“不可信数据”
4. 要求无法确定时明确说明，不凭空补齐

模型提示不是安全边界；权限、校验与敏感操作必须由程序控制。

本节路线

1. 消息协议
2. 生成参数
3. 响应处理
4. 多轮对话

长度与停止

- `max_tokens`：1–393216；仍受总上下文限制
- 默认：非思考 8K；思考 64K；max effort 128K
- `stop`：一个字符串或最多 16 个字符串
- `finish_reason=length`：内容可能被截断，不能当完整结果

采样参数

- `temperature`：0–2；低值更稳定，高值更多样
- `top_p`：核采样；通常只调整它或 temperature 之一
- 思考模式下 temperature 不生效，top_p 行为依模型而异
- `frequency_penalty` / `presence_penalty` 已不再支持

测试应固定提示、模式、参数并多次采样。

输出概率

`logprobs=true` 返回输出 Token 的对数概率；`top_logprobs` 为 0–20，且必须与 logprobs 一起使用。

适用于置信分析、候选观察与评测，不等同于事实正确率。

本节路线

1. 消息协议
2. 生成参数
3. 响应处理
4. 多轮对话

停止原因必须分支处理

原因	处理建议
stop	正常消费
length	增大预算或缩短上下文后重试
tool_calls	执行工具并回传结果
content_filter	告知无法完成，避免自动重试
insufficient_system_resource	退避重试
aborted	判断取消来源，按幂等性处理

响应字段

- 内容：`choices[0].message.content`
- 概率：`choices[0].logprobs`
- 推理：`message.reasoning_content`（第 4 课）
- 工具：`message.tool_calls`（第 6 课）
- 用量：`usage.prompt/completion/total_tokens`

生产代码不要假设 content 永远非空。

本节路线

1. 消息协议
2. 生成参数
3. 响应处理
4. 多轮对话

无状态多轮算法

1. 发送当前 `messages`
2. 把完整 assistant 消息追加到历史
3. 追加下一条 user 消息
4. 再次发送完整历史

数据库应保存结构化消息，而不是拼成一大段字符串。

上下文治理

- 保留系统规则与最近相关轮次
- 旧内容先摘要，再丢弃；摘要标明“可能有损”
- 工具调用及结果必须成对保留
- Token 预算 = 输入历史 + 期望输出 + 安全余量
- 不把不同最终用户的历史或缓存混用

user_id

`user_id` 用于内容安全、KVCache 和调度隔离；建议仅字母、数字、下划线、连字符，UTF-8 不超过 512 字节，且不得含隐私信息。

OpenAI SDK 当前可通过 `extra_body={"user_id": ...}` 传递。

本课例程与练习

1. `01_chat_parameters.py`：参数和停止原因
2. `02_multi_round.py`：交互式多轮历史

练习：加入历史长度上限；遇到 length 时输出明确错误，而不是展示半截答案。

官方资料

https://api-docs.deepseek.com/zh-cn/api/create-chat-completion
https://api-docs.deepseek.com/zh-cn/guides/multi_round_chat
https://api-docs.deepseek.com/zh-cn/quick_start/rate_limit