第 3 课：流式输出、用量与上下文缓存

SSE、保活、Token 账本与缓存命中

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 正确消费 Chat Completions 的 SSE 增量
- 识别正文、结束标记、保活与异常中断
- 读取流式 usage 并统计缓存命中
- 设计更容易命中 KV Cache 的上下文

本节路线

1. 流式协议
2. 用量账本
3. 上下文硬盘缓存

为什么流式

- 降低首字等待，提升长回答的交互体验
- 可逐步渲染，也可让用户主动取消
- 不降低总生成时间或 Token 费用
- 客户端需要处理半包、空增量和异常断开

Chat SSE 生命周期

HTTP 200 $\rightarrow$ role chunk $\rightarrow$ content/reasoning chunks
$\rightarrow$ finish chunk + usage $\rightarrow$ `data: [DONE]`

SDK 已解析 SSE；裸 HTTP 客户端需逐行处理 `data:`。

SDK 增量消费

```python
stream = client.chat.completions.create(
    model="deepseek-flash", messages=messages,
    stream=True,
    stream_options={"include_usage": True},
)
for chunk in stream:
    if chunk.choices:
        text = chunk.choices[0].delta.content or ""
        print(text, end="", flush=True)
    if chunk.usage:
        usage = chunk.usage
```

保活与超时

等待推理开始期间：非流式可能持续返回空行；流式可能收到 `: keep-alive` SSE 注释。它们不是正文。

若 10 分钟仍未开始推理，服务器会关闭连接。连接超时、读取超时和总任务超时应分开设置。

异常终止判断

- 收到 finish reason 和正常结束标记才算完整
- 只得到部分文本后断开：标记为不完整，不静默展示
- 自动重试可能重复生成或收费；先判断业务幂等性
- UI 将“正在生成、已完成、被取消、失败”分开

本节路线

1. 流式协议
2. 用量账本
3. 上下文硬盘缓存

usage 结构

`prompt_tokens` 总输入

`completion_tokens` 总输出

`total_tokens` 两者合计

`prompt_cache_hit_tokens` 缓存命中输入

`prompt_cache_miss_tokens` 未命中输入

流式请求需启用 `stream_options.include_usage`；最终块携带累计值。

不要只记总 Token

建议日志字段：请求 ID、模型、模式、首 Token 延迟、总延迟、停止原因、输入/命中/未命中/输出 Token、重试次数。

不记录消息正文也可做成本与性能分析，避免日志泄露敏感数据。

本节路线

1. 流式协议
2. 用量账本
3. 上下文硬盘缓存

自动缓存原理

DeepSeek 自动缓存请求上下文的共同前缀，无需创建缓存对象。新请求从头与已有缓存匹配，前缀相同部分可命中。

缓存命中影响价格与吞吐，不保证输出一致；采样仍可能产生不同回答。

提高命中率

- 稳定内容放前面：system、固定知识、工具定义
- 易变内容放后面：用户问题、时间、请求 ID
- 保持序列化稳定；不要无意义改变空格、顺序或模板版本
- 不为命中率牺牲用户隔离或上下文正确性

两类典型命中

多轮聊天

下一轮以完整上一轮为前缀，历史部分可命中。

长文问答

同一长文放在问题之前，多次提问共享文档前缀。

通过 usage 观察，不凭主观延迟判断。

流式与缓存常见误区

- 将每个 chunk 当完整 JSON 回答
- 忘记空字符串或空 choices
- 把 keep-alive 渲染给用户
- 中断后无条件重发
- 为缓存把不同用户数据混进同一前缀

本课例程

1. `01_stream_chat.py`：增量、结束与 usage
2. `02_cache_metrics.py`：同前缀两次请求的命中对比

练习：记录首 Token 时间，并在异常断开时丢弃或标记半成品。

官方资料

https://api-docs.deepseek.com/zh-cn/api/create-chat-completion
https://api-docs.deepseek.com/zh-cn/guides/kv_cache
https://api-docs.deepseek.com/zh-cn/quick_start/rate_limit