第 4 课：思考模式

推理强度、reasoning_content 与多轮规则

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 切换思考/非思考模式并设置推理强度
- 分离推理内容与最终回答
- 正确处理流式推理和多轮历史
- 理解工具存在时的特殊回传要求

本节路线

1. 控制方式
2. 参数与输出
3. 多轮规则

默认行为

当前模型默认开启思考模式，默认 effort 为 high。简单抽取、格式转换、低延迟交互可显式关闭；复杂推理、规划、代码分析可开启。

思考更强通常意味着更高延迟与更多输出 Token，并非所有任务都更好。

OpenAI Chat 两组参数

- 开关：`thinking.type = enabled/disabled`
- 强度：`reasoning_effort = low/high/max`
- thinking 优先；省略时由 effort 决定
- `reasoning_effort=none` 可关闭

SDK 中 thinking 通过 `extra_body` 传入。

跨协议映射

协议	开关	强度
Chat	thinking.type	reasoning_effort
Anthropic	thinking.type	output_config.effort
Responses	reasoning.effort	reasoning.effort

minimal→low；medium/xhigh→high；ultra→max。

显式开启

```
response = client.chat.completions.create(
    model="deepseek-flash",
    messages=messages,
    reasoning_effort="high",
    extra_body={"thinking": {"type": "enabled"}},
)
reasoning = response.choices[0].message.reasoning_content
answer = response.choices[0].message.content
```

本节路线

1. 控制方式
2. 参数与输出
3. 多轮规则

思考模式下的参数

- temperature、presence/frequency penalty 不生效
- Flash：top_p 有效范围 0.95–1；非思考时恒为 1
- Pro：思考时忽略 top_p；工具启用为 0.95，否则 1
- max_tokens 同时容纳推理与回答，预算不足会截断

兼容层可能静默接受但忽略参数，不能仅以“未报错”判断生效。

两条输出通道

reasoning_content 模型推理文本

content 面向用户的最终回答

产品界面可只展示最终答案；日志与存储应遵循隐私、安全和产品政策。不要把思维链当可验证证据。

流式拼接

同一流中 delta 可能携带 reasoning 或 content。分别累积，不要用 `else` 假定两者永不同时出现；字段为空是正常情况。

最终块检查 finish reason 与 usage，再将结果标记完成。

本节路线

1. 控制方式
2. 参数与输出
3. 多轮规则

不带 tools 的多轮

历史 `reasoning_content` 无需回传；即使传入也会被忽略，不拼入上下文。保存 assistant 的最终 content 即可延续普通聊天。

这减少历史体积，也避免把推理文本误当用户可见事实。

带 tools 的多轮

只要请求携带 `tools`，后续请求必须完整回传每轮 assistant 的 `reasoning_content`，即使该轮没有实际工具调用；否则可能返回 400。

最安全做法：原样追加 SDK 返回的完整 assistant message。

模式选择策略

任务	建议
分类、抽取、改写	disabled / none
普通问答	low 或 high，按评测选择
数学、复杂代码、规划	high / max
实时 UI	流式 + 合理 effort

用质量、P95 延迟、Token 与失败率共同评估。

常见错误

- 默认开启却误以为是普通快速模式
- 只打印 content，误判流式“长时间无输出”
- 为推理设置过小 max_tokens
- 带工具时丢掉 reasoning_content
- 把推理文本视为来源或审计证明

本课例程

1. `01_thinking.py`：非流式双通道
2. `02_thinking_stream.py`：流式分离推理与回答
3. `03_thinking_multi_turn.py`：不带工具的多轮

第 6 课再实现带工具的完整回传循环。

官方资料

https://api-docs.deepseek.com/zh-cn/guides/thinking_mode
https://api-docs.deepseek.com/zh-cn/api/create-chat-completion