第 5 课：结构化输出与补全能力

JSON Output、对话前缀续写与 FIM

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 生成可解析 JSON 并处理空白/截断
- 用 assistant 前缀约束回答开头
- 用 FIM 补全代码中间部分
- 认识 logprobs、Beta 地址和能力边界

本节路线

1. JSON Output
2. 对话前缀续写
3. FIM 补全
4. 概率与选择

开启 JSON 模式

设置 `response_format={"type":"json_object"}`，并在 system 或 user 提示中明确包含“JSON”字样及目标结构示例。

API 保证输出是合法 JSON 字符串，但不保证字段满足业务语义；仍需客户端 Schema 校验。

结构化请求

```
response = client.chat.completions.create(
  model="deepseek-flash",
  messages=[
    {"role": "system", "content":
      "输出 JSON: {\"name\": str, \"score\": int}"},
    {"role": "user", "content": "小明得 95 分"},
  ],
  response_format={"type": "json_object"},
  max_tokens=200,
)
data = json.loads(response.choices[0].message.content)
```

四层校验

1. `finish_reason != length`
2. content 非空且不是纯空格
3. `json.loads` 成功
4. 业务 Schema：必填字段、类型、范围、枚举

失败时缩短输入/扩大预算、改进示例后有限重试；不要无限重试同一提示。

特殊空白行为

若模型输出无法识别为 JSON，API 会把非 JSON 内容替换为 U+0020 空格；content 看似为空，但 finish reason 仍可能为 stop。

因此 `if not content.strip()` 是必需的防线。

本节路线

1. JSON Output
2. 对话前缀续写
3. FIM 补全
4. 概率与选择

Prefix Completion（Beta）

- 沿用 Chat Completions
- base URL 改为 `https://api.deepseek.com/beta`
- 最后一条必须是 assistant 消息
- 该消息设置 `prefix=True`

用于强制代码围栏、固定措辞开头或模板续写。

前缀 + stop

```
messages = [
  {"role": "user", "content": "写快速排序"},
  {"role": "assistant", "content": "```python\n",
   "prefix": True},
]
response = client.chat.completions.create(
  model="deepseek-flash", messages=messages,
  stop=["```"],
)
```

前缀只是生成约束，不是代码安全沙箱。

本节路线

1. JSON Output
2. 对话前缀续写
3. FIM 补全
4. 概率与选择

Fill In the Middle（Beta）

FIM 使用 `POST /beta/completions`：`prompt` 是前缀，`suffix` 是后缀，模型生成中间内容。适合 IDE 补全和局部模板填充。

最大补全长度为 4K；仅非思考模式支持。

Completion 参数与响应

- 输入：model、prompt、suffix、max_tokens、stop
- 可选：echo、logprobs、temperature、top_p、stream
- 输出文本：`choices[0].text`
- 用量结构与 Chat 类似，含缓存明细

FIM 上下文设计

- 前后缀应保留函数签名、缩进、类型与邻近依赖
- stop 阻止越界生成到下一函数/围栏
- 生成代码必须格式化、静态检查、测试后再采用
- 不把仓库密钥或无关私有代码发送给模型

本节路线

1. JSON Output
2. 对话前缀续写
3. FIM 补全
4. 概率与选择

什么时候用哪一种

目标	能力
可靠机器读取	JSON Output + 本地 Schema 校验
固定回答开头	Chat Prefix（Beta）
补全中间代码	FIM（Beta）
观察候选 Token	logprobs / top_logprobs

本课例程

1. `01_json_output.py`：解析与兜底
2. `02_prefix_completion.py`：代码前缀续写
3. `03_fim_completion.py`：中间补全

官方资料

https://api-docs.deepseek.com/zh-cn/guides/json_mode
https://api-docs.deepseek.com/zh-cn/guides/chat_prefix_completion
https://api-docs.deepseek.com/zh-cn/guides/fim_completion
https://api-docs.deepseek.com/zh-cn/api/create-completion