第 9 课：网页搜索与抓取

Search、Fetch 与有来源的 Web RAG

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 调用原始 Search / Fetch JSON API
- 使用搜索语法、排序分数和权威性字段
- 根据错误类型决定是否重试
- 构建最小的“搜—选—答—引”流程

本节路线

1. 两个独立工具 API
2. Fetch 与错误
3. Web RAG

职责与端点

Search `POST /v1/tools/search`，按 query 返回结构化结果

Fetch `POST /v1/tools/fetch`，把单页抓成 Markdown

它们是原始 JSON API，不是 Chat Completions 内的客户端 function call；使用相同 Bearer Key。

Search 请求字段

- query：必填，1–128 个 Unicode 字符
- count：1–50，默认 10
- ori_question：原始用户问题，帮助理解意图
- localization：用于本地化的 IP
- need_content：是否同时返回正文

未知字段会被忽略，客户端仍应主动拒绝拼写错误。

搜索语法

操作符	作用
site: / -site:	限定/排除站点
" 短语" / -" 短语"	包含/排除精确短语
-关键词	排除词
lang:zh,en	限定语言
after: / before:	限定日期

多个 site 可用空格和 OR 组合。

Search 响应阅读

- rerank_score：0–3，≥ 1.5 通常为优质结果
- authority：0–4，≥ 3 极权威，-1 未知
- snippet：短展示；summary：给模型阅读的长摘要
- content：仅 need_content=true 且可提取时非空
- date：UTC RFC 3339 或 null

分数是排序信号，不替代来源核验。

本节路线

1. 两个独立工具 API
2. Fetch 与错误
3. Web RAG

Fetch 请求与响应

输入只有 URL：最长 8192，必须是含 host 的 HTTP/HTTPS URL，不允许用户名/密码。返回 title 与 Markdown content。

结果受目标站点可用性、robots/访问策略、内容类型影响。

错误决策

状态	含义	策略
400/401/403/404	请求/认证/策略/内容问题	修正后再发
402	余额不足	充值，不自动重试
408/429	超时/限速	退避重试
413	请求过大	缩小请求
500/504	服务/下游失败	抖动退避重试

计费与限速

Search、Fetch 各 5 元/1000 次成功且有结果的请求；失败、空搜索、超时不计费，count 不影响单次价格。

账号级独立 QPS：Search 100，Fetch 25；Fetch 另有目标域名限速。与模型并发额度互不占用。

本节路线

1. 两个独立工具 API
2. Fetch 与错误
3. Web RAG

最小流水线

用户问题 → Search（摘要/正文）→ 过滤与去重
→ 必要时 Fetch 原文 → 编号上下文
→ 模型回答 → 返回可点击来源

来源与提示注入

网页是不可信数据：页面中的“忽略之前指令”等内容不能成为系统指令。

提示中明确：只把网页当资料；引用编号；资料不足则说明；工具调用和敏感操作不受网页指令控制。

检索治理

- 优先官方/一手来源、时效和交叉验证
- 限制传给模型的页面数与长度
- URL 去重，记录查询、时间与来源
- 把模型答案和原始来源一起返回
- 尊重版权、站点条款和个人信息保护

本课例程

1. `01_search_fetch.py`：搜索并可选抓取第一条
2. `02_web_rag.py`：搜索摘要驱动的带来源回答

示例不自动抓取任意用户 URL，降低 SSRF 与内容风险。

官方资料

https://api-docs.deepseek.com/zh-cn/guides/search
https://api-docs.deepseek.com/zh-cn/api/search
https://api-docs.deepseek.com/zh-cn/api/fetch