第 10 课：Responses API

Items、语义流事件与 Codex 兼容

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 用 Responses API 完成文本与图片输入
- 理解 input/output items 和语义化流事件
- 完成 function call 的无状态回传
- 区分完整支持、部分支持、忽略与不支持字段

本节路线

1. 请求与响应
2. 语义化流
3. 工具与视觉
4. 兼容边界

最小调用

`client.responses.create(model, instructions, input)`；`input` 与 `instructions` 至少提供一个。最终文本可从 `response.output_text` 读取。

base URL 仍为 `https://api.deepseek.com`。

为什么是 Items

Responses 不只输出消息，而是有序 output item：reasoning、message、function_call、custom_tool_call、web_search_call 等。

多轮仍是无状态的：需要把先前相关 items 与工具结果重新放入 input。

输入 item 支持

- message：user/assistant/system/developer；文本与 input_image
- function_call / function_call_output
- reasoning：明文 content；summary/encrypted_content 不支持
- custom_tool_call/output：仅配合 apply_patch
- 其他类型通常忽略

developer 在兼容层视同 user；文件输入不支持。

最小 Python

```python
response = client.responses.create(
  model="deepseek-flash",
  instructions="回答简洁。",
  input="什么是 Responses API？",
  reasoning={"effort": "none"},
  max_output_tokens=300,
)
print(response.output_text)
```

本节路线

1. 请求与响应
2. 语义化流
3. 工具与视觉
4. 兼容边界

与 Chat SSE 的差别

Responses 事件有 `type` 和递增 `sequence_number`；以 response.completed/incomplete/failed 结束，没有 data: [DONE]。

只在 completed 才视为正常完成；incomplete 常见于输出预算不足。

关键事件

- response.created / in_progress
- response.output_item.added/done
- response.reasoning_text.delta/done
- response.output_text.delta/done
- response.function_call_arguments.delta/done
- response.completed / incomplete / failed

最终事件中的 response 携带完整 usage。

本节路线

1. 请求与响应
2. 语义化流
3. 工具与视觉
4. 兼容边界

工具支持矩阵

- function：支持
- custom：仅 name=apply_patch，用于 Codex
- web_search：仅 Pro 服务端执行；Flash 忽略
- file_search、code_interpreter、computer_use、mcp：忽略

parallel_tool_calls 被忽略，实际始终允许并行。

function 回传

响应的 function_call 含 call_id、name、arguments；执行后把 `function_call_output`（同 call_id）加入下一次 input。

依然需要白名单、参数校验、权限、超时和最大循环步数。

图片输入

`input_image` 使用 image_url 或 file_id（二者互斥），可设 detail。仅 Flash 真正处理；允许出现在 user/developer 或工具输出，system/assistant 中图片返回 400。

本节路线

1. 请求与响应
2. 语义化流
3. 工具与视觉
4. 兼容边界

常用支持字段

model、input、instructions、stream、temperature、top_p、max_output_tokens、top_logprobs、tools、tool_choice、reasoning.effort、text.format、user。

部分支持或忽略

- reasoning.summary 可传但不生成
- text.verbosity 可传但不生效
- 不支持 previous_response_id / conversation：无状态
- store 固定 false；background、metadata、include 等不支持
- truncation 不支持，超上下文返回 400
- 不支持字段多会静默忽略

服务端搜索用量

Pro 的 web_search 由服务端执行并继续生成，无需客户端回传结果。
`usage.server_tool_use` 统计 tool_search / tool_fetch；流式时从最终事件读取。

服务端搜索同样按成功调用计费。

本课例程

1. `01_responses_basic.py`：基础与 reasoning
2. `02_responses_stream.py`：语义流事件
3. `03_responses_tool.py`：function items 循环

官方资料

https://api-docs.deepseek.com/zh-cn/guides/responses_api
https://api-docs.deepseek.com/zh-cn/api/create-response