第 11 课：Anthropic Messages API

生态迁移、内容块、工具与流式用量

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 用 Anthropic SDK 调用 DeepSeek
- 理解模型映射与字段兼容性
- 实现 tool_use / tool_result 循环
- 正确读取流式事件、缓存与服务端工具用量

本节路线

1. 接入基础
2. 字段兼容
3. 工具与思考
4. 服务端工具与流

地址与鉴权

base URL：`https://api.deepseek.com/anthropic`。可用 `x-api-key` 或 `Authorization: Bearer`。

Anthropic SDK 要求显式 max_tokens；裸 HTTP 可省略，由模型/模式决定默认值。

模型名映射

- claude-opus* → deepseek-v4-pro（按 Pro 计费）
- claude-haiku* / claude-sonnet* → deepseek-flash
- 直接使用 deepseek-flash / deepseek-v4-pro 最清晰
- 非 claude 前缀的未知模型名返回 400

映射用于兼容受模型名限制的客户端，不应掩盖真实成本。

最小调用

```
client = anthropic.Anthropic(
  api_key=os.environ["DEEPSEEK_API_KEY"],
  base_url="https://api.deepseek.com/anthropic",
)
message = client.messages.create(
  model="deepseek-flash", max_tokens=500,
  system="回答简洁。",
  messages=[{"role":"user", "content":"你好"}],
)
```

本节路线

1. 接入基础
2. 字段兼容
3. 工具与思考
4. 服务端工具与流

常用字段

system、messages、stop_sequences、stream 完全支持；metadata 仅 user_id 生效。thinking 支持 enabled/disabled，adaptive 视为 enabled，budget_tokens 忽略；output_config 仅 effort 生效。

会被忽略的字段

container、mcp_servers、service_tier、top_k、cache_control、text citations 等被忽略。思考模式 temperature 固定 1；top_p 行为仍依 Flash/Pro。

兼容成功不等于语义完全相同，应建立迁移测试。

消息内容块

支持 text、thinking、tool_use、tool_result、server_tool_use、web_search_tool_result；不支持 document、search_result、redacted_thinking、MCP/代码执行结果等。

Flash 支持 user 和 tool_result 中的 image；Pro 替换为 `[Unsupported Image]`。

本节路线

1. 接入基础
2. 字段兼容
3. 工具与思考
4. 服务端工具与流

客户端工具定义

工具直接提供 name、description、input_schema，不要给客户端函数传 type=custom，否则 422。

tool_choice：none/auto 支持；any 按 auto；指定 tool 仅非思考模式支持。

回传工具结果

assistant 若含 tool_use，紧接的消息必须是 user，并为所有调用提供匹配 tool_use_id 的 tool_result；该 user 消息中所有 tool_result 必须放在文本之前。

思考工具链

建议原样回传 assistant 完整 content 数组（thinking + tool_use）。服务端有时能按调用 ID 恢复遗漏推理，但无法恢复会 400，不要依赖自动恢复。

本节路线

1. 接入基础
2. 字段兼容
3. 工具与思考
4. 服务端工具与流

Anthropic 服务端 web search

声明 web_search 服务端工具后，由服务端执行并继续回答，客户端无需 tool_result。输出含 server_tool_use 与 web_search_tool_result。

`usage.server_tool_use` 区分尝试次数 web_search_requests 与成功有结果次数 tool_search。

流式事件

message_start → content_block_start/delta/stop → message_delta → message_stop，期间可有 ping 和保活注释；没有 `data: [DONE]`。

最终 Token 以 message_delta.usage 为准，不与 message_start 相加。

Anthropic usage

总输入 = input_tokens + cache_read_input_tokens + cache_creation_input_tokens；当前 cache creation 常为 0。流式中断且未收到 message_stop，响应不完整。

图片与 Files

image.source.type 可为 base64、url、file。file 图片和 Anthropic Files API 必须带 `anthropic-beta: files-api-2025-04-14`；Files 路径、分页和字段差异见第 8 课。

本课例程

1. `01_anthropic_basic.py`：基础消息与思考控制
2. `02_anthropic_stream.py`：流式文本与最终用量
3. `03_anthropic_tool.py`：工具内容块循环

官方资料

https://api-docs.deepseek.com/zh-cn/guides/anthropic_api
https://api-docs.deepseek.com/zh-cn/api/create-message