第 12 课：生产可靠性与成本治理

错误、退避、并发、隔离、观测与预算

DeepSeek API 全栈课程

文档快照：2026-11-05

学习目标

- 按错误类别设计重试与降级
- 管理并发、超时、取消和 user_id 隔离
- 建立不泄密的可观测性与成本账本
- 把“能调用”提升为“可安全上线”

本节路线

1. 错误分类
2. 并发与超时
3. 可观测性
4. 成本与安全

核心 HTTP 错误

状态	原因	默认动作
400	请求格式	修正，不原样重试
401	Key 无效	停止并轮换/修正
402	余额不足	告警并充值
422	参数错误	修正字段
429	并发/速率上限	抖动退避
500/503	服务故障/繁忙	有界退避

退避公式

第 n 次等待可取 $\min(cap, base \times 2^n) + random(0, jitter)$。

只重试临时错误；设置最大次数和总时限；尊重服务端 Retry-After（若有）；记录最终失败原因。

幂等性问题

生成请求重试可能产生不同文本和重复费用；工具写操作更可能造成重复副作用。

业务层使用请求 ID/幂等键、工具去重、状态机和人工确认。不要把网络重试与业务重试混为一谈。

本节路线

1. 错误分类
2. 并发与超时
3. 可观测性
4. 成本与安全

当前账号并发上限

模型	官方快照并发
deepseek-flash	2500
deepseek-v4-pro	500

一次请求从发出到响应完成持续占用并发；限制按账号而非 API Key。生产端还要设置更低的本地信号量，保护自身资源。

user_id 隔离

用于内容安全、KVCache 和调度隔离。建议字符集为字母/数字/下划线/连字符，UTF-8 最多 512 字节，不得放邮箱、手机号等隐私。

Chat 放 extra_body.user_id；Responses 用 user；Anthropic 用 metadata.user_id。

超时分层

- 连接超时：网络/握手
- 首字超时：排队 + 开始推理
- 读取空闲超时：流中断
- 总截止时间：整个业务请求
- 工具自身超时：外部依赖

服务端会发送空行或 SSE 注释保活；10 分钟未开始推理可能关闭。

本节路线

1. 错误分类
2. 并发与超时
3. 可观测性
4. 成本与安全

结构化日志字段

request id、业务 trace id、模型、API 形态、模式/effort、状态码、重试次数、首 Token/总延迟、finish reason、Token 分类、工具次数。

默认不记录 Key、完整提示、推理文本、图片或工具敏感参数。

四类核心指标

- 可靠性：成功率、429/5xx、异常断流、重试耗尽
- 性能：P50/P95 首字与总延迟、工具耗时
- 质量：任务成功率、Schema 校验率、人工评分
- 成本：命中/未命中输入、输出、搜索/抓取调用

本节路线

1. 错误分类
2. 并发与超时
3. 可观测性
4. 成本与安全

成本公式

模型费 = 缓存命中输入 × 对应单价 + 未命中输入 × 单价 + 输出 × 单价。Search/Fetch 按成功有结果的调用计费。

价格分时且会变化，应用只记录用量；账单服务从配置读取当前单价。

成本控制杠杆

- 按任务路由 Flash/Pro 和思考强度
- 限制输出、工具步数、搜索次数与输入历史
- 稳定前缀提高缓存命中
- 对租户/用户设置日预算和熔断
- 质量评测后再降级，避免“便宜但无用”

密钥与数据安全

服务端持有 Key；最小权限、定期轮换、泄漏即吊销。提示与网页防注入；工具执行器做授权；日志脱敏；上传文件设生命周期；数据保留遵循业务和法规。

上线检查清单

- 有界重试、熔断、限流、超时、取消
- 全部分支处理 finish reason / 终止事件
- Schema 与工具参数本地校验
- 指标、告警、预算和降级开关
- 负载、故障、注入、权限与数据恢复演练

本课例程

1. `01_resilient_chat.py`：分类重试与抖动退避
2. `02_bounded_parallel.py`：本地并发上限
3. `03_observable_request.py`：脱敏结构化指标

官方资料

https://api-docs.deepseek.com/zh-cn/quick_start/error_codes
https://api-docs.deepseek.com/zh-cn/quick_start/rate_limit
https://api-docs.deepseek.com/zh-cn/quick_start/pricing
https://api-docs.deepseek.com/zh-cn/guides/kv_cache